

Proyecto 3 - AST0421

Modelado de SEDs y Análisis de parámetros para AGNs con CIGALE

Fecha de Entrega: 05/11/2023

ALUMNO: JORGE I. DIMTER,¹ PROFESOR: EZEQUIEL TREISTER,¹ AND
AYUDANTES: CLEMENTE RIESCO Y MARCO TRONCOSO¹

¹*Instituto de Astrofísica, Facultad de Física, Pontificia Universidad Católica de Chile*

ABSTRACT

Se presenta el modelado de SED para 19 AGNs con datos detallados para múltiples longitudes de onda de AHA survey. Se utilizó CIGALE para realizar los ajustes de espectro, considerando módulos para modelar la SFH, la contribución de las poblaciones estelares, la emisión nebular, la atenuación y emisión del polvo, y el aporte del AGN, entre otros. El proceso se repitió hasta que la mayoría de los modelos mostraran un valor de χ^2_{red} menor a 2.5. Se recuperó la tasa de formación estelar instantánea, la edad de la población estelar principal, masa estelar total, exceso de color E(B-V) entre poblaciones jóvenes y viejas (Δ 10 Myr), luminosidad total del AGN en rayos X, luminosidad total de AGN y poder de acreción. Se generaron las PDF para cada parámetro recuperado. Posteriormente se analizaron las correlaciones entre parámetros usando los índices de Pearson y Kendall τ . Se consideraron las 5 correlaciones con valor absoluto mayor a 0.3, correspondiente a una correlación fuerte. La edad de la población estelar principal muestra una correlación negativa con la SFR y E(B-V). La masa estelar total muestra una correlación positiva con la SFR y la luminosidad del AGN en rayos X. Finalmente se estudió la correlación positiva existente entre la luminosidad total del AGN con la luminosidad del disco de acreción. Se discute el posible origen de las correlaciones y posibles soluciones para la obtención de un análisis estadístico significativo.

1. INTRODUCCIÓN

Los núcleos galácticos activos (AGNs, por sus siglas en inglés) son fuentes astrofísicas de alta energía, alimentadas por la acreción de agujeros negros supermasivos (SMBH) en los centros de las galaxias y presentan observaciones únicas que cubren todo el espectro electromagnético con más de veinte órdenes de magnitud en frecuencia (Padovani et al. (2017); Marshall et al. (2022)). Tanto las propiedades de la galaxia y su correspondiente SMBH pueden ser obtenidas a través del análisis de espectros de AGN. Sin embargo, desde la llegada de grandes surveys de estudios de galaxias en múltiples longitudes de onda, el ajuste la distribución de energía espectral (SED) se ha empleado rutinariamente para inferir corrimientos al rojo fotométricos (ver Salvato et al. (2019)), así como propiedades físicas (ver Walcher et al. (2011); Johnson et al. (2021); Thorne et al. (2022) para ver los métodos mas utilizados). Para longitudes de onda ultravioleta y ópticas, la gran parte

del enfoque en el modelado de SEDs a estado en mejorar los modelos de síntesis de poblaciones estelares para representar de mejor manera las emisiones de las galaxias (Conroy et al. (2013)). Técnicas bayesianas también han sido utilizadas para limitar las propiedades de las SED. Considerando el modelado de SEDs, se entiende que los parámetros pueden tener degeneraciones complejas multidimensionales en los espacios de modelado (Lower et al. (2020)), y subestimar las incertezas reales en los modelos puede tener grandes consecuencias sobre lo que podamos concluir sobre la formación y evolución de la galaxia observada (Curtis-Lake et al. (2021)). Para galaxias de alto redshift, la comprensión de que las líneas de emisión puede contribuir de forma significativa en el flujo de ciertas bandas, y que por lo tanto influye en el modelado de la SED, ha revolucionado la comprensión de los ajustes de SED (Smit et al. (2014)). Al mismo tiempo han habido notables avances en las técnicas de modelado de SEDs, que utilizan un enfoque auto

consistente para modelar al mismo tiempo la emisión ultravioleta e infrarrojo cercana de las galaxias por ejemplo CIGALE (utilizado para la realización de este proyecto y explicado en mayor detalle en la Sección 3), MAGPHYS (da Cunha et al. (2008)). Los componentes de AGN se incorporan normalmente en los códigos de modelado de SED que cubren un amplio rango de longitudes de onda, dado que estos últimos pueden ayudar a romper degeneraciones existentes entre los parámetros de AGN y de la galaxia anfitriona (Rivera et al. (2016)).

El proyecto presentado a continuación tiene como objetivo llevar a cabo el modelado de los espectros de energía de 19 núcleos activos galácticos. Se entregarán los gráficos de las mejores SEDs resultantes para cada objeto. Posteriormente se realizará un análisis sobre las posibles relaciones y degeneración de ciertas propiedades físicas, tales como sus poblaciones estelares, extinción, tasa de formación estelar, contribución y luminosidad del AGN, oscurecimiento del AGN, entre otros posibles. Todo esto último en conjunto con un análisis de errores mediante la obtención de la función de distribución de probabilidad (PDF) y discusión sobre los mejores ajustes. Se compararán los resultados obtenidos por minimización de χ^2 e inferencia Bayesiana y se discutirán distintas opciones para poder mejorar los resultados.

2. DESCRIPCIÓN DE DATOS

Los datos fueron obtenidos del set de 1246 galaxias con AGN analizadas por Auge et al. (2023). Del set de datos original se consideró una muestra de 19 objetos aleatorios, de los cuales se recibió el redshift espectroscópico, el flujo en unidades mJy y los errores correspondientes para 22 bandas.

Este trabajo utiliza datos detallados de múltiples longitudes de onda de la encuesta AHA, que está compuesta por tres campos de encuesta con diferentes profundidades y cobertura del cielo. Juntos, estos campos crean una "encuesta de pastel de bodas", donde cada campo investiga una zona y límite de flujo diferente, y, por lo tanto, detecta AGN en un rango diferente de luminosidad y desplazamiento al rojo. El campo más grande corresponde a Stripe 82X (LaMassa et al. (2013); Ananna et al. (2017)), que consiste en un wide-area survey en rayos X que cubre $\sim 31\text{deg}^2$ del campo Legacy SDSS Stripe 82 (Jiang et al. (2014)). La parte intermedia corresponde a el campo COSMOS (Scoville et al. (2007); Elvis et al. (2009); Civano et al. (2016)), que corresponde a un survey de campo amplio, profundo y de múltiples longitudes ondas que cubre un campo de 2deg^2 centrado en las coordenadas $RA = +150.119$

and $Dec = +2.205$ (J2000). La última parte corresponde a GOODS (Giavalisco et al. (2004)). Ambos campos GOODS, GOODS norte y sur, utilizan observaciones profundas, cubriendo en conjunto un total de 320arcmin^2 y contienen los flujos límites más profundos del AHA survey.

3. CODE INVESTIGATING GALAXY EMISSION (CIGALE)

CIGALE es un código desarrollado para estudiar la evolución de galaxias comparando distribuciones de energía espectral modeladas con las observadas, en un rango de longitudes de onda que va desde rayos X y ultravioleta lejano, hasta el infrarrojo lejano y ondas de radio. CIGALE utiliza la arquitectura de computadores multinúcleo y construye grandes cantidades de modelos para analizar propiedades de galaxias. Se utiliza para estimar parámetros e inferir propiedades de galaxias (Boquien et al. (2019)).

Para calcular los modelos espectrales, CIGALE construye poblaciones estelares compuestas a partir de poblaciones estelares simples combinadas con historias de formación estelar altamente flexibles, luego calcula la emisión de gas ionizado por estrellas masivas y atenúa las estrellas y el gas ionizado con una cierta curva de atenuación. Cumpliendo con el principio de equilibrio energético, la energía absorbida se emite nuevamente por el polvo en los dominios infrarrojo mediano y lejano, mientras que se incluyen los componentes termales y no termales, extendiendo así el espectro al rango de ondas de radio. Finalmente se ajusta una gran cantidad de modelos a los datos y se estiman las propiedades físicas usando la distribución de probabilidad.

CIGALE también entrega tres ejecutables, cada uno con un propósito específico. Estos ejecutables se listan a continuación:

- **pcigale** Realiza el cálculo de los modelos y estima las propiedades físicas de las galaxias en caso de ser necesario.
- **pcigale-plots** Genera gráficos con los resultados obtenidos por *pcigale*. Los gráficos que genera son; el mejor ajuste de SED, distribución de χ^2 , PDFs y estimaciones de propiedades físicas.
- **pcigale-filters** Permite enumerar, eliminar, agregar o trazar un filtro en la base de datos.

En la Sección 4 a continuación se explican los módulos utilizados para obtener los ajustes.

4. ANÁLISIS DE DATOS Y RESULTADOS

4.1. Módulos

Para correr CIGALE se requiere definir los módulos a utilizar, con los respectivos grados de libertad para cada parámetro, siempre considerando mientras mas opciones distintas se tengan por parámetro, al agregar uno nuevo aumenta considerablemente la cantidad de modelos y en consecuencia la demanda computacional. A continuación se explican los módulos utilizados mas relevantes.

4.1.1. SFH

La evolución de las galaxias resulta de gran complejidad considerando la acreción y expulsión de gas, las distintas interacciones y distintos mecanismos que puedan afectar su proceso evolutivo. De esto último resulta que la SFR muestra distintas variaciones no triviales, las cuales por mas distintas que puedan ser, tiene la posibilidad de generar espectros de energía simulados virtualmente iguales. Es por esto ultimo que se suelen considerar SFHs simples dentro de las cuales se encuentran; exponenciales decrecientes o crecientes y retardadas, entre otras. Sin embargo, con simulaciones numéricas cada vez más detalladas, ahora también es posible adoptar SFH más realistas derivadas directamente de tales simulaciones o modelos semi-analíticos (Pacifi et al. (2012); Boquien et al. (2014)). Para abarcar estos dos enfoques, CIGALE maneja tanto SFH analíticas que dependen de varios parámetros, como SFH arbitrarias. En la Figura 1 se muestra la evolución temporal de distintos tipos de SFR.




Figure 1. SFH generada con los modulos *sfh2exp*, *sfhdelayed* y *sfhperiodic*. Recuperada de Boquien et al. (2019).

Para la realización de este proyecto se utilizó *sfhdelayed*. La repentina aparición de la formación estelar y

los episodios de explosión en una parametrización doble exponencial pueden ser demasiado extremos en muchos casos prácticos en los que esperamos que la variación de la SFH sea más suave. Una forma cada vez más popular de modelar la SFH de las galaxias es la llamada SFH delayed (retardada). Esta SFR viene dada por la expresión dada en la Ecuación 1.

$$\text{SFR}(t) \propto \frac{t}{\tau^2} \times \exp\left(-\frac{t}{\tau}\right) \text{ para } 0 \leq t \leq t_0, \quad (1)$$

con t_0 como la edad de inicio de la formación estelar y τ como el momento en que la SFR alcanza su punto máximo. Esta forma tiene la ventaja de proporcionar un aumento casi lineal de la SFR desde el inicio de la formación estelar en lugar de uno abrupto en el caso de *sfh2exp*. Después de alcanzar su máximo en $t = \tau$, disminuye de manera suave.

4.1.2. Poblaciones Estelares

Una vez teniendo definida la SFH, el paso siguiente es calcular el espectro estelar intrínseco. Para poder lograr esto, además de la SFH necesitamos adoptar una librería de poblaciones estelares simples (SSPs, por sus siglas en inglés). Para el desarrollo del proyecto, se utilizó el modelo *bc03* desarrollado por Bruzual & Charlot (2003). Luego de esto ya contamos con poblaciones libres de polvo. Para compensar el efecto de enrojecimiento diferencial entre poblaciones jóvenes rodeadas de nubes de polvo y poblaciones viejas que han escapado, por lo que están menos enrojecidas (Charlot & Fall (2000a)). Para considerar esto último se calcula el espectro de manera separada para ambos tipos de poblaciones, considerando una separación arbitraria inicial de 10 Myr.

4.1.3. Emisión Nebular

Las estrellas mas masivas emiten un parte importante de su luz en la serie de Lyman. Estos fotones de alta energía tiene la capacidad de ionizar el gas que les rodea, el cual re-emite la energía en una serie de líneas de emisión y continuo que se extiende hasta el régimen de ondas de radio. La emisión nebular generalmente contribuye muy poco en los flujos de banda ancha en galaxias en proceso de formación estelar. Este modulo se utilizó solo para el primer set de parámetro y luego fue eliminado para mejorar el tiempo de computo. Es importante considerar que la emisión nebular puede tomar gran importancia para galaxias muy jóvenes en proceso de formación estelar tanto como galaxias de alto redshift.

4.1.4. Atenuación

Las galaxias contienen polvo, y este polvo es muy eficiente en la absorción de radiación de corta longi-

tud de onda. La energía absorbida desde el ultravioleta hasta el infrarrojo cercano se emite luego en el infrarrojo medio y lejano. Este principio de equilibrio energético es fundamental en CIGALE. Por lo tanto, es importante que la atenuación se modele adecuadamente. Para modelar la atenuación se utilizó el módulo *dustatt_modified_starburst module*. Este ultimo se basa la curva de atenuación para starbursts descrita por Calzetti et al. (2000) y extendida usando la curva de Leitherer et al. (2002). Se le puede cambiar la pendiente multiplicandola por una función de ley de potencia con una pendiente dada. También se puede añadir un peak en el UV, el cual se modela como un perfil tipo Lorentziano descrito por su longitud de onda central, FWHM y amplitud.

4.1.5. Emisión de Polvo

El polvo tiene la capacidad de absorber fotones dentro un rango espectral grande, el cual va de UV hasta NIR. Esta energía es luego re-emitida en longitudes de onda mas grandes; MIR y FIR. Para modelar la emisión de polvo se utilizó el módulo *dale2014*, el cual está basado en los templates de polvo de Dale et al. (2014).

4.1.6. AGN

Junto con la formación estelar, se cree que los AGN tienen un impacto significativo en la evolución de las galaxias. Sin embargo, separar adecuadamente las emisiones de los AGN de las de la formación estelar no siempre es una tarea sencilla, ya que ambos pueden emitir fuertemente en la región del ultravioleta (UV), y una gran parte de esta emisión puede ser procesada por el polvo y reemitida en longitudes de onda más largas. Se utilizó el módulo *SKIRTOR* desarrollado por Stalevski et al. (2012).

4.2. Resultados

Dentro de los parámetros físicos generados correspondientes al modulo de historia de formación estelar, *sfdelayed* encontramos la tasa de formación estelar instantánea, la edad de la población estelar principal de la galaxia y su metalicidad. Respecto al módulo de poblaciones estelar *bc03*, se obtuvo el parámetro de masa estelar total. Para el modulo atenuación de polvo *dustatt_modified_starburst* obtuvimos el exceso de color de la luz estelar para la población vieja y joven. Del modulo *X-ray* se obtuvo la luminosidad total del AGN en rayos X y del módulo *SKIRTOR* se obtuvieron los parámetros de la suma de luminosidad de polvo y de disco del AGN y el poder de acreción, correspondiente a la luminosidad intrínseca del disco del AGN promediada en todas las direcciones. En la Tabla 1 se muestran los valores

de χ^2 reducido obtenidos para tres archivos .ini distintos, con el fin de encontrar los menores valores posibles para cada objeto. Los valores del mejor ajuste obtenidos para cada parámetro se muestran en la Tabla 2 con sus respectivos errores relativos en la Tabla 3.

ID Objeto	ini0	ini1	ini2
342090.0	2.17	2.23	3.3
698425.0	1.59	-	-
414248.0	1.77	-	-
508074.0	2.409	2.33	0.96
688836.0	1.29	-	-
128954.0	7.66	4.6	3.55
637663.0	1.29	-	-
724318.0	2.05	2.12	2.15
625595.0	5.66	3.75	2.21
491067.0	3.65	8.34	2.87
725161.0	3.56	3.63	2.97
341626.0	4.29	5.66	4.75
317570.0	16.02	37.35	4.29
616226.0	2.56	2.73	2.69
735335.0	5.86	3.90	4.63
286866.0	2.28	2.22	2.34
650453.0	11.66	13.57	2.03
900353.0	3.15	1.95	2.54
458021.0	4.45	4.65	15.32

Table 1. Valores de χ^2_{red} para tres conjuntos de parámetros diferentes.

De manera preliminar se analizaron las correlaciones entre parámetros haciendo uso de dos indicadores de correlación distintos. Esto con el fin de poder encontrar de manera cuantitativa parámetros con posibles degeneraciones, dado que considerando la baja cantidad de datos, resulta difícil poder identificar estructuras de manera visual. El coeficiente de correlación de Pearson (PCC) es un coeficiente de correlación que mide la correlación lineal entre dos conjuntos de datos. Es la proporción entre la covarianza de dos variables y el producto de sus desviaciones estándar; por lo tanto, es básicamente una medida normalizada de la covarianza, de modo que el resultado siempre tiene un valor entre -1 y 1. Al igual que la covarianza en sí misma, esta medida solo puede reflejar una correlación lineal entre las variables, y no tiene en cuenta muchos otros tipos de relaciones o correlaciones.

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (2)$$

ID Objeto	Parámetros Obtenidos por Galaxia							
	SFR	Age Main	Z	Stellar Mass	E(B-V)	Luminosity	Acc. Power	XRay Lum
458021.0	10.64	2000	0.05	2.6e+10	0.560	3.23e+37	2.06e+37	4.02e+37
342090.0	27.92	2000	0.02	1.9e+10	0.480	7.68e+36	3.51e+36	1.05e+37
698425.0	22.37	2000	0.02	1.9e+10	0.560	3.06e+37	2.25e+37	1.04e+37
414248.0	13.45	2000	0.02	3.8e+10	0.540	7.89e+36	5.05e+36	9.83e+36
508074.0	26.57	3000	0.02	1.8e+10	0.480	9.07e+36	5.34e+36	5.20e+36
688836.0	6.043	3000	0.02	4.0e+10	0.480	4.88e+36	2.72e+36	7.62e+36
128954.0	11.33	2000	0.02	3.5e+10	0.540	2.04e+37	1.47e+37	1.24e+37
637663.0	39.85	2000	0.02	6.4e+10	0.540	1.55e+37	2.11e+37	0.00e+00
724318.0	67.03	2000	0.02	3.9e+10	0.480	7.80e+37	3.21e+37	2.90e+37
625595.0	42.69	2000	0.02	4.1e+10	0.630	1.64e+37	6.58e+36	2.13e+37
491067.0	45.08	2000	0.02	6.2e+10	0.480	7.85e+37	6.09e+37	9.35e+37
725161.0	67.98	5000	0.02	1.7e+10	0.200	1.59e+37	9.17e+36	1.49e+37
341626.0	4.453	5000	0.02	3.9e+11	0.600	2.12e+38	1.42e+38	1.13e+38
317570.0	3.582	7000	0.02	5.9e+10	0.600	3.44e+37	2.31e+37	1.84e+37
616226.0	6.980	5000	0.02	1.1e+11	0.375	2.16e+38	8.29e+37	7.44e+37
735335.0	27.19	5000	0.02	4.1e+10	0.320	2.17e+37	2.12e+37	1.69e+37
286866.0	17.67	5000	0.02	6.9e+10	0.600	6.48e+38	5.35e+38	7.06e+37
650453.0	30.16	5000	0.02	1.3e+11	0.320	8.41e+36	6.85e+36	6.14e+36
900353.0	1.213	5000	0.02	2.4e+10	0.225	8.35e+37	5.60e+37	4.47e+37

Table 2. Mejor valor de ajuste para parámetros de cada galaxia.

ID Objeto	Error relativo por parámetro							
	SFR	Age Main	Z	Stellar Mass	E(B-V)	Luminosity	Acc. Power	XRay Lum
458021.0	0.165	2.28e-01	2.54e-01	0.17	5.05e-02	0.15	0.190	0.172
342090.0	0.055	1.08e-01	2.24e-01	0.10	7.03e-02	0.09	0.139	0.229
698425.0	0.119	2.24e-01	1.88e-01	0.14	4.82e-02	0.06	0.096	0.079
414248.0	0.203	2.49e-01	7.48e-01	0.16	6.11e-02	0.50	0.982	0.233
508074.0	0.104	3.57e-02	2.80e-01	0.06	1.28e-02	0.09	0.125	0.167
688836.0	0.349	1.62e-01	7.01e-01	0.12	3.55e-02	0.10	0.567	0.261
128954.0	0.049	1.47e-03	1.57e-03	0.05	1.47e-02	0.10	0.270	0.207
637663.0	0.083	1.12e-01	3.29e-02	0.09	1.76e-02	0.08	0.109	-
724318.0	0.049	2.40e-02	9.10e-03	0.05	8.20e-02	0.05	0.082	0.086
625595.0	0.182	2.27e-01	7.30e-01	0.20	1.01e-01	0.16	0.240	0.179
491067.0	0.051	9.72e-02	1.37e-01	0.17	8.82e-05	0.05	0.151	0.101
725161.0	0.081	1.58e-01	3.17e-16	0.07	5.71e-02	0.05	0.053	0.196
341626.0	5.240	1.81e-16	3.66e-16	0.28	1.91e-01	0.07	0.153	0.178
317570.0	0.390	1.22e-01	3.58e-16	0.29	2.75e-01	0.46	0.815	0.191
616226.0	0.261	4.35e-16	3.97e-16	0.09	8.70e-02	0.12	0.338	0.084
735335.0	0.054	2.97e-02	1.58e-16	0.05	4.48e-03	0.09	0.064	0.069
286866.0	0.050	2.58e-16	3.88e-16	0.05	5.89e-10	0.05	0.050	0.050
650453.0	0.081	3.35e-02	5.20e-16	0.08	1.49e-01	3.57	5.540	0.245
900353.0	0.256	9.80e-16	6.53e-16	0.13	2.29e-01	0.11	0.200	0.174

Table 3. Errores relativos de ajuste para parámetros de cada galaxia.

Donde r representa el coeficiente de correlación de Pearson. n es el número de puntos de datos. X_i y Y_i son los puntos de datos individuales para las dos variables. $\bar{X}$ y $\bar{Y}$ son las medias de las variables X e Y , respectivamente.

Por su parte, la ecuación de Kendall Tau compara la cantidad de pares de observaciones en los que los valores tienen la misma dirección de cambio (positivo o negativo) con la cantidad de pares en los que los valores tienen una dirección de cambio diferente. El resultado, τ , representa la fuerza y dirección de la correlación entre los dos conjuntos de datos. Un valor de τ cercano a 1 indica una fuerte correlación positiva, un valor cercano a -1 indica una fuerte correlación negativa, y un valor cercano a 0 indica una falta de correlación.

$$\tau = \frac{2}{n(n-1)} \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(x_i - x_j) \text{sgn}(y_i - y_j) \quad (3)$$

donde τ (Tau) representa el coeficiente de correlación de Kendall. Es el valor que se calcula y que indica la fuerza y dirección de la correlación entre dos conjuntos de datos. n : Es el número total de pares de observaciones en tus datos. En otras palabras, es el tamaño de tu muestra o la cantidad de elementos en tus conjuntos de datos. x_i y y_i : Estos son los valores de las dos variables que estás comparando. x_i y y_i representan los valores de la i -ésima observación en los dos conjuntos de datos que estás evaluando. x_j y y_j : Estos son los valores de las variables para otra observación en tus conjuntos de datos. x_j y y_j representan los valores de la j -ésima observación. $\text{sgn}(u)$: La función "sgn(u)" es la función de signo. Devuelve -1 si u es negativo, 0 si u es cero y 1 si u es positivo. En la ecuación de Kendall Tau, se utiliza para comparar las diferencias entre los valores de las observaciones x_i y x_j , así como y_i y y_j . En la Figura 2 se muestran los valores obtenidos para ambos índices de correlación.

Podemos ver que los dobletes de parámetros con mayor índice de correlación para ambos tests corresponde a la edad de la población estelar principal y la tasa de formación estelar, junto con la luminosidad y el poder de acreción. El primer doblete muestra una fuerte anticorrelación y el segundo una correlación positiva casi absoluta alcanzando valores de 0.87 y 0.98. Luego también se consideraran los dobletes de exceso de color con edad de la población estelar principal y la masa estelar total con la luminosidad del AGN en rayos X. En la Sección 5 se muestran los gráficos obtenidos para los dobletes de parámetros mencionado y se incluye el gráfico de masa estelar total y SFR considerando lo




Figure 2. Mapa de calor de correlaciones entre parámetros. En el triángulo inferior de la matriz se observan los valores de coeficientes obtenidos usando el índice de correlación de Pearson. El triángulo superior de la matriz son los valores de coeficiente de correlación de Kendall τ .

realizado por [Renzini & Peng \(2015\)](#).

Para saber que tan buena es la estimación de un parámetro se suele obtener la función de distribución de probabilidad (PDF). Las PDFs son herramientas valiosas para interpretar la incerteza en diversos campos. Estas funciones encapsulan la incertidumbre al ilustrar la probabilidad de diferentes resultados para una variable aleatoria. La tendencia central, a menudo representada por la moda, indica el valor más probable, mientras que la amplitud y variabilidad del PDF transmiten el grado de incertidumbre: cuanto más amplio sea el PDF, mayor será la incertidumbre. Las PDFs se utilizan para estimar intervalos de confianza, permitiendo visualizar no solo las estimaciones centrales, sino también el rango de valores probables. La asimetría y la skewness (se refiere a la tendencia de los valores en esa distribución a agruparse más hacia un lado del valor promedio o la media, es decir, si la distribución es simétrica o si está desplazada hacia la izquierda) revelan si una PDF tiene una inclinación positiva o negativa, ofreciendo información sobre la probabilidad de valores que se desvían de la media. Además, las PDFs destacan valores extremos, donde las PDFs con colas anchas indican una mayor probabilidad de valores atípicos. Más allá de la media y la desviación estándar, momentos superiores como la curtosis brindan más detalles sobre las características de la distribución. La visualización de la incertidumbre a través de PDFs, especialmente en el contexto de la estimación de parámetros, predicciones

de modelos y análisis bayesianos, proporciona una vista integral de los posibles resultados. Para entender mejor el concepto, a continuación se muestran PDFs para distintos parámetros para los objetos con mejor y peor χ^2_{red} al momento de correr *ini0*. En la Figura 6 se muestran ejemplos de PDFs bien y mal comportadas para algunos de los parámetros analizados en la Sección 5, para el caso del objeto con mejor valor de χ^2_{red} .

5. DISCUSIÓN




Figure 3. Gráfico para la edad de la población estelar principal versus la tasa de formación estelar (arriba) y el exceso de color $E(B-V)$ (abajo).

Estudios previos han sugerido que el enrojecimiento por parte del polvo en estrellas en proceso de formación estelar está relacionado con la SFR, lo cual puede ser bien estimado usando la luminosidad intrínseca de $H\alpha$ (Kennicutt (1998); Calzetti et al. (2010)). Las galaxias que muestran una alta SFR (equivalente también a una alta luminosidad, lo cual no se ve reflejada en los coeficientes de correlación) muestran líneas de extinción

globales fuertes en la líneas de emisión. Galaxias con una alta SFR muestran una fuerte extinción local en las líneas de emisión, esto se debe principalmente a la presencia de polvo interestelar en esas galaxias. Este polvo actúa como un filtro que absorbe y dispersa la luz, especialmente la luz ultravioleta y azul, lo que afecta la observación de las líneas de emisión (Wang & Heckman (1996); Charlot & Fall (2000b); Charlot & Fall (2000b); Stasińska & Sodr  (2001); Kewley et al. (2004)).

Además, se ha reconocido que el enrojecimiento del polvo también podría ser función de la metalicidad en fase gaseosa, es decir, el enrojecimiento y la extinción aumentan con la metalicidad. Por ejemplo, el enrojecimiento promedio de las regiones [HII] en una galaxia individual se correlaciona con la metalicidad en el disco (e.g. Quillen & Yukita (2001); Boissier et al. (2004)). Garn & Best (2010) encontraron una importante correlación entre la extinción del polvo y la metalicidad, sin embargo, afirman que la dependencia entre el enrojecimiento y la masa estelar es mas fundamental.

Considerando esto ultimo, podemos entender la relación entre enrojecimiento y la edad de la población estelar principal de la misma, con los trabajos de Noeske et al. (2007), Elbaz et al. (2007) Daddi et al. (2007) y Pannella et al. (2009), quienes han demostrado que la formación estelar y la masa estelar definen una estrecha correlación en las galaxias en $z \sim 1$ y $z \sim 2$, con una proporcionalidad aproximada (una pendiente logarítmica de ~ 1.0). También se observa una proporcionalidad similar en $z = 0$ en los datos del SDSS (Elbaz et al. (2007)). En Zhao et al. (2011) se ilustra la relación entre SFR y masa estelar, mostrando una buena correlación, con coeficiente de Spearman de $\rho = 0.68$ (3.5σ). Sin embargo, se evidencia una dispersión significativa en la tendencia, es decir, para una masa estelar determinada, la SFR puede variar en un orden de magnitud.

Es esperable que la SFR muestre una correlación negativa con la edad de la población estelar debido a que las poblaciones más jóvenes tienen formación estelar activa, mientras que las poblaciones más antiguas consisten principalmente en estrellas que han completado su fase de secuencia principal y ya no forman nuevas estrellas de manera activa.

La correlación entre la luminosidad en rayos X y la masa estelar se puede explicar con la dependencia entre masa estelar y luminosidad bolométrica Preibisch et al. (2008). Para la masa estelar versus la SFR se muestran las zonas de mayor densidad de muestras con contornos.




Figure 4. Gráfico para la masa estelar total versus la luminosidad total del AGN en rayos X (arriba) y la tasa de formación estelar E(B-V) (abajo). En este ultimo se agrega la Estimación de Densidad de Kernel (KDE, por sus siglas en inglés), que es un método estadístico no paramétrico utilizado para estimar la función de densidad de probabilidad (PDF) de una variable aleatoria continua. Con esto podemos identificar de manera mas fácil la zona mas poblada.

Se puede observar un posible outlier que se escapa de las zonas mas densas mostrando un valor de χ^2_{red} de aproximadamente 3.5. Podemos ver que la diferencia entre los valores maximos y mínimos de SFR y de masa estelar corresponde aproximadamente a un diferencia de un orden de magnitud, por lo que se puede entender que la SFR escala de manera casi lineal con la masa estelar. Dado que la SFR es muy aproximadamente la derivada temporal de la masa estelar, esto implica que la SFR es una función creciente con el tiempo (Salmon et al. (2015)).

El poder de acreción es el termino que se usa para referirse a la luminosidad intrínseca del disco de acreción




Figure 5. Gráfico para la luminosidad versus el poder de acreción.

Padilla et al. (2021). Asumiendo una correlación lineal se obtuvo que la recta que modela de mejor manera los datos tiene una pendiente de 0.78. Lo que implica que el aporte del disco de acreción a la luminosidad del AGN corresponde a las tres cuartas partes de su luminosidad total.

6. CONCLUSIONES

La selección de los módulos y su variedad de parámetros resulta de suma importancia, donde se deben considerar los valores para cada parámetro. Las distintas libertades en cada parámetro entregaron una intuición sobre la degeneración entre sí y que tipo de modulo afecta en mayor manera una zona específica del espectro electromagnético. La elección de cantidad de valores por parámetro es también un aspecto importante a considerar dado que ésta afecta significativamente la demanda computacional.

Para obtener los modelos de SED CIGALE brinda la flexibilidad de emplear el ajuste bayesiano como también determinar los mejores resultados utilizando la estadística del χ^2 , cada uno con su conjunto de ventajas y limitaciones. El ajuste bayesiano, por un lado, incorpora información previa, conocido como prior, un activo valioso cuando se dispone de conocimiento previo. Produce posterior PDFs para cada parámetro, lo que permite una exploración más completa de las incertidumbres y la adaptación a modelos complejos y relaciones no lineales. Sin embargo, puede ser intensivo desde el punto de vista computacional, especialmente con modelos intrincados y conjuntos de datos extensos, y la elección de las distribuciones previas puede introducir subjetividad. En contraste, el enfoque de

mejor ajuste, utilizando la estadística del χ^2 , es eficiente desde el punto de vista computacional y ofrece una interpretación sencilla con un único conjunto de valores de parámetros que minimizan el χ^2 . Puede servir como una exploración inicial rápida del espacio de parámetros. Sin embargo, tiene limitaciones en el sentido de que no cuantifica las incertidumbres, asume errores distribuidos normalmente, no incorpora fácilmente información previa y puede conducir a overfitting. Esto último resulta especialmente complicado al momento de considerar la degeneración entre parámetros, dado que sets de valores de parámetros muy distintos pueden generar distribuciones espectrales muy similares. Considerando que el software a elección pueda no considerar todos los parámetros mas relevantes para cierto tipo de objeto, el ajuste que mejor minimice χ^2 podría ser un mínimo local que se encuentra en otra zona del espacio de exploración de parámetros. Métodos como el bootstrap se pueden aplicar a expensas de repetir el procedimiento de ajuste muchas veces. Una técnica que se ha vuelto cada vez más popular en la última década para abordar estos problemas es depender de la bondad del ajuste de todos los modelos en lugar de solo el modelo de mejor ajuste. Esto se hace generalmente a través de la verosimilitud. Estas verosimilitudes luego se pueden usar como ponderaciones para estimar tanto los parámetros físicos (las medias ponderadas por la verosimilitud de los parámetros físicos) como las incertidumbres relacionadas (las desviaciones estándar ponderadas por la verosimilitud de los parámetros físicos). Este método funciona bien cuando la función de distribución de probabilidad es bien comportada (por ejemplo, tiene un peak). Para casos más difíciles, la función de distribución de probabilidad marginalizada proporciona toda la información para estimar las propiedades físicas [Boquien et al. \(2019\)](#). La elección entre estos métodos depende de los objetivos de investigación específicos, las características de los datos y los recursos computacionales disponibles, a menudo implicando una combinación de ambos enfoques para equilibrar la eficiencia y la robustez en los análisis de modelos.

AQUI HABLAR QUIZAS DE LAS PDFs

Los índices de correlaciones calculados en la Sección 4 (ver Figura 2) mostraron una predominancia para las correlaciones lineales, dadas por un valor $|x| > 0.3$ en la correlación de Pearson. De las correlaciones obtenidas se estudiaron las 5 mas altas, correspondientes a; edad de la población estelar principal con el exceso de color $E(B-V)$ y la SFR, la masa estelar total con la luminosidad total del AGN en rayos X y la SFR, y finalmente la

luminosidad total del AGN versus el poder de acreción, que corresponde a la luminosidad del disco de acreción.

Respecto a las dos primera correlaciones; estudios previos han indicado que el enrojecimiento causado por el polvo en estrellas en proceso de formación estelar está relacionado con la SFR y se puede estimar con la luminosidad intrínseca de $H\alpha$. Las galaxias con altas SFR muestran extinciones globales fuertes en las líneas de emisión, y aquellas con alta SFR también presentan extinciones locales notables debido a la presencia de polvo interestelar que actúa como un filtro de absorción y dispersión de la luz, especialmente la ultravioleta y la azul. Además, se ha observado que el enrojecimiento del polvo podría aumentar con la metalicidad en fase gaseosa. A esto último es importante agregar que se ha identificado una correlación entre la extinción del polvo y la metalicidad, aunque algunos investigadores sugieren que la dependencia entre el enrojecimiento y la masa estelar es más fundamental. La relación entre enrojecimiento y la edad de la población estelar principal también se ha explorado, mostrando que la SFR tiende a disminuir con la edad de la población estelar, ya que las poblaciones más jóvenes están más activas en la formación estelar en comparación con las poblaciones más antiguas, que consisten principalmente en estrellas que han completado su fase de secuencia principal y ya no están formando nuevas estrellas activamente.

La correlación entre luminosidad de AGN en rayos X y la masa estelar total se relacionan dada la dependencia entre la luminosidad bolométrica y la misma masa estelar. Por su parte la masa estelar y la SFR muestran una relación lineal y casi directa. La masa estelar total establece el potencial general para la formación de estrellas dentro de una galaxia. Las galaxias con masas estelares más grandes tienen un mayor depósito de gas y polvo, que puede convertirse en nuevas estrellas. Esto significa que tienen la capacidad de tener una Tasa de Formación Estelar (SFR) más alta si las condiciones son adecuadas. La excepción se encuentra en las galaxias Quiescentes, dado que estas galaxias suelen tener masas estelares más grandes y han completado en su mayoría sus principales fases de formación estelar. Por lo general, se encuentran fuera de la secuencia principal. Otra excepción se encuentra en las Galaxias Starburst. Estas galaxias muestran starbursts, que son breves períodos de intensa formación de estrellas y tienen SFR elevadas en comparación con lo que se esperaría según su masa estelar total. Aunque existe una correlación entre la masa estelar total y la SFR, también hay una dispersión en esta relación. Esta dispersión puede atribuirse a

varios factores, incluida la presencia de polvo, diferentes contenidos de gas y variaciones locales dentro de una galaxia.

La luminosidad del disco de acreción está relacionada con la luminosidad total del AGN porque el disco de acreción es la principal fuente de energía en un AGN (Gaskell (2007)). A medida que este material cae en el agujero negro, libera una gran cantidad de energía potencial gravitatoria. Esta energía se convierte en radiación, y la luminosidad del disco de acreción representa la tasa a la cual esta energía se emite en forma de luz. En la mayoría de los AGNs, el disco de acreción es la fuente dominante de radiación. Puede eclipsar a la galaxia anfitriona y a otros componentes del AGN. Los AGNs son conocidos por su variabilidad en luminosidad en diferentes escalas de tiempo, desde días hasta años (Ulrich et al. (1997)). La luminosidad del disco de acreción a menudo es responsable de estas variaciones. Monitorear los cambios en la luminosidad del disco de acreción puede ayudar a comprender los procesos dinámicos que ocurren en los núcleos activos.

Un análisis mas detallado y con mas rigor estadístico requiere de un set de datos considerablemente mayor y una exploración mayor del espacio de parámetros. Esto ultimo permitiría discernir entre mínimos locales y globales, lo cual nos acercaría de mejor forma a las propiedades físicas reales del objeto modelado.




Figure 6. PDF para cada parámetro recuperado. Se puede observar que aquellos parámetros con los cuales se exploró un mayor número de posibles valores la PDF toma forma esperada. Para el E(B-V) podemos ver que a pesar de haber probado pocos parámetros, es posible distinguir un peak claro, el cual debería suavizarse al aumentar la exploración de valores. Un ejemplo un tanto más complicado es el de la luminosidad del AGN en rayos X, ya que presentan dos peaks. A pesar de esto último resulta posible identificar uno predominante. La edad de la población principal y la metalicidad son dos casos donde la PDF se comporta de mala forma. En el caso de la metalicidad queda evidenciado que solo se tomó un posible valor de 0.02. Estos casos podrían indicar que por más bueno que sea el ajuste, nos podemos encontrar en un mínimo local.




Figure 7. Distribuciones de energía espectral modeladas por CIGALE.

REFERENCES

- Ananna, T. T., Salvato, M., LaMassa, S., et al. 2017, *ApJ*, 850, 66, doi: [10.3847/1538-4357/aa937d](https://doi.org/10.3847/1538-4357/aa937d)
- Auge, C., Sanders, D., Treister, E., et al. 2023, *The Accretion History of AGN: The Spectral Energy Distributions of X-ray Luminous AGN*. <https://arxiv.org/abs/2308.10710>
- Boissier, S., Boselli, A., Buat, V., Donas, J., & Milliard, B. 2004, *A&A*, 424, 465, doi: [10.1051/0004-6361:20047024](https://doi.org/10.1051/0004-6361:20047024)
- Boquien, M., Buat, V., & Perret, V. 2014, *A&A*, 571, A72, doi: [10.1051/0004-6361/201424441](https://doi.org/10.1051/0004-6361/201424441)
- Boquien, M., Burgarella, D., Roehlly, Y., et al. 2019, *A&A*, 622, A103, doi: [10.1051/0004-6361/201834156](https://doi.org/10.1051/0004-6361/201834156)
- Bruzual, G., & Charlot, S. 2003, *MNRAS*, 344, 1000, doi: [10.1046/j.1365-8711.2003.06897.x](https://doi.org/10.1046/j.1365-8711.2003.06897.x)
- Calzetti, D., Armus, L., Bohlin, R. C., et al. 2000, *ApJ*, 533, 682, doi: [10.1086/308692](https://doi.org/10.1086/308692)
- Calzetti, D., Wu, S. Y., Hong, S., et al. 2010, *ApJ*, 714, 1256, doi: [10.1088/0004-637X/714/2/1256](https://doi.org/10.1088/0004-637X/714/2/1256)
- Charlot, S., & Fall, S. M. 2000a, *ApJ*, 539, 718, doi: [10.1086/309250](https://doi.org/10.1086/309250)
- . 2000b, *ApJ*, 539, 718, doi: [10.1086/309250](https://doi.org/10.1086/309250)
- Civano, F., Marchesi, S., Comastri, A., et al. 2016, *ApJ*, 819, 62, doi: [10.3847/0004-637X/819/1/62](https://doi.org/10.3847/0004-637X/819/1/62)
- Conroy, C., Dutton, A. A., Graves, G. J., Mendel, J. T., & van Dokkum, P. G. 2013, *The Astrophysical Journal Letters*, 776, L26, doi: [10.1088/2041-8205/776/2/L26](https://doi.org/10.1088/2041-8205/776/2/L26)
- Curtis-Lake, E., Chevallard, J., Charlot, S., & Sandles, L. 2021, *Monthly Notices of the Royal Astronomical Society*, 503, 4855, doi: [10.1093/mnras/stab698](https://doi.org/10.1093/mnras/stab698)
- da Cunha, E., Charlot, S., & Elbaz, D. 2008, *MNRAS*, 388, 1595, doi: [10.1111/j.1365-2966.2008.13535.x](https://doi.org/10.1111/j.1365-2966.2008.13535.x)
- Daddi, E., Dickinson, M., Morrison, G., et al. 2007, *ApJ*, 670, 156, doi: [10.1086/521818](https://doi.org/10.1086/521818)
- Dale, D. A., Helou, G., Magdis, G. E., et al. 2014, *The Astrophysical Journal*, 784, 83, doi: [10.1088/0004-637X/784/1/83](https://doi.org/10.1088/0004-637X/784/1/83)
- Elbaz, D., Daddi, E., Le Borgne, D., et al. 2007, *A&A*, 468, 33, doi: [10.1051/0004-6361:20077525](https://doi.org/10.1051/0004-6361:20077525)
- Elvis, M., Civano, F., Vignali, C., et al. 2009, *The Astrophysical Journal Supplement Series*, 184, 158, doi: [10.1088/0067-0049/184/1/158](https://doi.org/10.1088/0067-0049/184/1/158)
- Garn, T., & Best, P. N. 2010, *MNRAS*, 409, 421, doi: [10.1111/j.1365-2966.2010.17321.x](https://doi.org/10.1111/j.1365-2966.2010.17321.x)
- Gaskell, C. M. 2007, *Accretion Disks and the Nature and Origin of AGN Continuum Variability*. <https://arxiv.org/abs/0711.2113>
- Gialalisco, M., Dickinson, M., Ferguson, H. C., et al. 2004, *The Astrophysical Journal*, 600, L103, doi: [10.1086/381244](https://doi.org/10.1086/381244)
- Jiang, L., Fan, X., Bian, F., et al. 2014, *The Astrophysical Journal Supplement Series*, 213, 12, doi: [10.1088/0067-0049/213/1/12](https://doi.org/10.1088/0067-0049/213/1/12)
- Johnson, B. D., Leja, J., Conroy, C., & Speagle, J. S. 2021, *The Astrophysical Journal Supplement Series*, 254, 22
- Kennicutt, Robert C., J. 1998, *ARA&A*, 36, 189, doi: [10.1146/annurev.astro.36.1.189](https://doi.org/10.1146/annurev.astro.36.1.189)
- Kewley, L. J., Geller, M. J., & Jansen, R. A. 2004, *AJ*, 127, 2002, doi: [10.1086/382723](https://doi.org/10.1086/382723)
- LaMassa, S. M., Urry, C. M., Cappelluti, N., et al. 2013, *Monthly Notices of the Royal Astronomical Society*, 436, 3581, doi: [10.1093/mnras/stt1837](https://doi.org/10.1093/mnras/stt1837)
- Leitherer, C., Li, I.-H., Calzetti, D., & Heckman, T. M. 2002, *The Astrophysical Journal Supplement Series*, 140, 303, doi: [10.1086/342486](https://doi.org/10.1086/342486)
- Lower, S., Narayanan, D., Leja, J., et al. 2020, *The Astrophysical Journal*, 904, 33, doi: [10.3847/1538-4357/abbfa7](https://doi.org/10.3847/1538-4357/abbfa7)
- Marshall, A., Auger-Williams, M. W., Banerji, M., Maiolino, R., & Bowler, R. 2022, *Monthly Notices of the Royal Astronomical Society*, 515, 5617, doi: [10.1093/mnras/stac1619](https://doi.org/10.1093/mnras/stac1619)
- Noeske, K. G., Weiner, B. J., Faber, S. M., et al. 2007, *ApJL*, 660, L43, doi: [10.1086/517926](https://doi.org/10.1086/517926)
- Pacifici, C., Kassin, S. A., Weiner, B., Charlot, S., & Gardner, J. P. 2012, *The Astrophysical Journal Letters*, 762, L15, doi: [10.1088/2041-8205/762/1/L15](https://doi.org/10.1088/2041-8205/762/1/L15)
- Padilla, A. F. R., Wang, L., Malek, K., Efsthathiou, A., & (), G. Y. 2021, *Monthly Notices of the Royal Astronomical Society*, 510, 687, doi: [10.1093/mnras/stab3486](https://doi.org/10.1093/mnras/stab3486)
- Padovani, P., Alexander, D. M., Assef, R. J., et al. 2017, *The Astronomy and Astrophysics Review*, 25, doi: [10.1007/s00159-017-0102-9](https://doi.org/10.1007/s00159-017-0102-9)
- Pannella, M., Carilli, C. L., Daddi, E., et al. 2009, *ApJL*, 698, L116, doi: [10.1088/0004-637X/698/2/L116](https://doi.org/10.1088/0004-637X/698/2/L116)
- Preibisch, T., Kim, Y.-C., Favata, F., et al. 2008, *The Astrophysical Journal Supplement Series*, 160, 401, doi: [10.1086/432891](https://doi.org/10.1086/432891)
- Quillen, A. C., & Yukita, M. 2001, *The Astronomical Journal*, 121, 2095
- Renzini, A., & Peng, Y.-j. 2015, *ApJL*, 801, L29, doi: [10.1088/2041-8205/801/2/L29](https://doi.org/10.1088/2041-8205/801/2/L29)
- Rivera, G. C., Lusso, E., Hennawi, J. F., & Hogg, D. W. 2016, *The Astrophysical Journal*, 833, 98, doi: [10.3847/1538-4357/833/1/98](https://doi.org/10.3847/1538-4357/833/1/98)
- Salmon, B., Papovich, C., Finkelstein, S. L., et al. 2015, *The Astrophysical Journal*, 799, 183, doi: [10.1088/0004-637x/799/2/183](https://doi.org/10.1088/0004-637x/799/2/183)

- Salvato, M., Ilbert, O., & Hoyle, B. 2019, *Nature Astronomy*, 3, 212, doi: [10.1038/s41550-018-0478-0](https://doi.org/10.1038/s41550-018-0478-0)
- Scoville, N., Aussel, H., Brusa, M., et al. 2007, *ApJS*, 172, 1, doi: [10.1086/516585](https://doi.org/10.1086/516585)
- Smit, R., Bouwens, R. J., Labbé, I., et al. 2014, *ApJ*, 784, 58, doi: [10.1088/0004-637X/784/1/58](https://doi.org/10.1088/0004-637X/784/1/58)
- Stalevski, M., Fritz, J., Baes, M., Nakos, T., & Popović, L. Č. 2012, *MNRAS*, 420, 2756, doi: [10.1111/j.1365-2966.2011.19775.x](https://doi.org/10.1111/j.1365-2966.2011.19775.x)
- Stasińska, G., & Sodr , L., J. 2001, *A&A*, 374, 919, doi: [10.1051/0004-6361:20010831](https://doi.org/10.1051/0004-6361:20010831)
- Thorne, J. E., Robotham, A. S. G., Davies, L. J. M., et al. 2022, *MNRAS*, 509, 4940, doi: [10.1093/mnras/stab3208](https://doi.org/10.1093/mnras/stab3208)
- Ulrich, M.-H., Maraschi, L., & Urry, C. M. 1997, *ARA&A*, 35, 445, doi: [10.1146/annurev.astro.35.1.445](https://doi.org/10.1146/annurev.astro.35.1.445)
- Walcher, J., Groves, B., Budav ri, T., & Dale, D. 2011, *Ap&SS*, 331, 1, doi: [10.1007/s10509-010-0458-z](https://doi.org/10.1007/s10509-010-0458-z)
- Wang, B., & Heckman, T. M. 1996, *ApJ*, 457, 645, doi: [10.1086/176760](https://doi.org/10.1086/176760)
- Zhao, Y., Gu, Q., & Gao, Y. 2011, *The Astronomical Journal*, 141, 68, doi: [10.1088/0004-6256/141/2/68](https://doi.org/10.1088/0004-6256/141/2/68)

Analisis de Resultados - Proyecto 3

November 5, 2023

```
[2]: import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import astropy
import corner
import arviz
import reportlab
```

```
[4]: #sfh.sfr, sfh.age_main, stellar.metallicity, stellar.m_star, attenuation.E_BVs,
↪agn.luminosity, agn.accretion_power, xray.agn_Lx_total
```

```
[5]: from astropy.io import ascii

# Specify the file path
file_path1 = 'out01/results.txt'
file_path2 = 'out02/results.txt'
file_path3 = 'out03/results.txt'

table1 = ascii.read(file_path1)
table2 = ascii.read(file_path2)
table3 = ascii.read(file_path3)
```

0.0.1 Corrigiendo out1

```
[6]: def remove_values_at_indices(input_list):
    indices_to_remove = [3,5,8,9,10,12,13,14,15,16,17]
    result_list = [value for index, value in enumerate(input_list) if index not
↪in indices_to_remove]
    return result_list
```

```
[7]: lista_chi2_red = remove_values_at_indices(list(table1['best.
↪reduced_chi_square']))+list(table2['best.
↪reduced_chi_square']))+list(table3['best.reduced_chi_square'])
```

```
[8]: lista_agn_L_6um = remove_values_at_indices(list(table1['best.agn.
↪L_6um']))+list(table2['best.agn.L_6um']))+list(table3['best.agn.L_6um'])
```

```
err_agn_L_6um = remove_values_at_indices(list(table1['best.agn.
↳L_6um']))+list(table2['best.agn.L_6um'])+list(table3['best.agn.L_6um'])
```

```
[9]: lista_sfr = remove_values_at_indices(list(table1['best.sfh.
↳sfr']))+list(table2['best.sfh.sfr'])+list(table3['best.sfh.sfr'])
lista_age_main = remove_values_at_indices(list(table1['best.sfh.
↳age_main']))+list(table2['best.sfh.age_main'])+list(table3['best.sfh.
↳age_main'])
lista_metallicity= remove_values_at_indices(list(table1['best.stellar.
↳metallicity']))+list(table2['best.stellar.metallicity'])+list(table3['best.
↳stellar.metallicity'])
lista_m_star= remove_values_at_indices(list(table1['best.stellar.
↳m_star']))+list(table2['best.stellar.m_star'])+list(table3['best.stellar.
↳m_star'])
lista_E_BVs= remove_values_at_indices(list(table1['best.attenuation.
↳E_BVs']))+list(table2['best.attenuation.E_BVs'])+list(table3['best.attenuation.
↳E_BVs'])
lista_luminosity= remove_values_at_indices(list(table1['best.agn.
↳luminosity']))+list(table2['best.agn.luminosity'])+list(table3['best.agn.
↳luminosity'])
lista_accretion_power= remove_values_at_indices(list(table1['best.agn.
↳accretion_power']))+list(table2['best.agn.accretion_power'])+list(table3['best.
↳agn.accretion_power'])
lista_agn_Lx_total= remove_values_at_indices(list(table1['best.xray.
↳agn_Lx_total']))+list(table2['best.xray.agn_Lx_total'])+list(table3['best.xray.
↳agn_Lx_total'])
```

```
[10]: samples = np.
↳vstack([lista_sfr,lista_age_main,lista_metallicity,lista_m_star,lista_E_BVs,lista_luminosity,
```

```
[13]: err_sfr = remove_values_at_indices(list(table1['bayes.sfh.
↳sfr_err']))+list(table2['bayes.sfh.sfr_err'])+list(table3['bayes.sfh.sfr_err'])
err_age_main = remove_values_at_indices(list(table1['bayes.sfh.
↳age_main_err']))+list(table2['bayes.sfh.age_main_err'])+list(table3['bayes.sfh.
↳age_main_err'])
err_metallicity= remove_values_at_indices(list(table1['bayes.stellar.
↳metallicity_err']))+list(table2['bayes.stellar.
↳metallicity_err'])+list(table3['bayes.stellar.metallicity_err'])
err_m_star= remove_values_at_indices(list(table1['bayes.stellar.
↳m_star_err']))+list(table2['bayes.stellar.m_star_err'])+list(table3['bayes.
↳stellar.m_star_err'])
err_E_BVs= remove_values_at_indices(list(table1['bayes.attenuation.
↳E_BVs_err']))+list(table2['bayes.attenuation.E_BVs_err'])+list(table3['bayes.
↳attenuation.E_BVs_err'])
```


```

err_luminosity= remove_values_at_indices(list(table1['bayes.agn.
↳luminosity_err']))+list(table2['bayes.agn.luminosity_err'])+list(table3['bayes.
↳agn.luminosity_err'])
err_accretion_power= remove_values_at_indices(list(table1['bayes.agn.
↳accretion_power_err']))+list(table2['bayes.agn.
↳accretion_power_err'])+list(table3['bayes.agn.accretion_power_err'])
err_agn_Lx_total= remove_values_at_indices(list(table1['bayes.xray.
↳agn_Lx_total_err']))+list(table2['bayes.xray.
↳agn_Lx_total_err'])+list(table3['bayes.xray.agn_Lx_total_err'])

```

```
[96]: plt.scatter(table1['bayes.stellar.m_star'],table1['best.stellar.m_star'])
```

```
[96]: <matplotlib.collections.PathCollection at 0x1353f7490>
```



```
[14]: def error(lista,err):
      return np.array(err)/np.array(lista)
```

```
[174]: error(lista_sfr,err_sfr)
```

```
[174]: array([0.16588167, 0.05476995, 0.11954061, 0.20297836, 0.10474784,
            0.34927925, 0.04990754, 0.08275765, 0.04954536, 0.182037 ,
            0.05130531, 0.0814045 , 5.24664388, 0.39029514, 0.2617089 ,
            0.05407883, 0.04994535, 0.08085239, 0.25625441])
```

```
[175]: error(lista_age_main,a_age_main)
```

```
[175]: array([2.28344172e-01, 1.08583267e-01, 2.24206835e-01, 2.49347538e-01,
            3.57366105e-02, 1.62222847e-01, 1.47893514e-03, 1.12699453e-01,
            2.40611191e-02, 2.27832030e-01, 9.72724027e-02, 1.58516502e-01,
            1.81898940e-16, 1.22049319e-01, 4.35829495e-16, 2.97548898e-02,
            2.58064881e-16, 3.35177177e-02, 9.80273705e-16])
```

```
[181]: error(lista_agn_Lx_total,err_agn_Lx_total)
```

```

/tmp/ipykernel_46334/1665389276.py:2: RuntimeWarning: divide by zero encountered
in divide
    return np.array(err)/np.array(lista)

```

```
[181]: array([0.17207832, 0.2293181 , 0.07875658, 0.23314855, 0.16661053,
          0.26139873, 0.20710418,          inf, 0.0859731 , 0.17924207,
          0.10113765, 0.19606032, 0.17842806, 0.19133285, 0.08382502,
          0.06871512, 0.04997637, 0.24489061, 0.17367238])
```

```
[385]: data = {
    'sfr': lista_sfr,
    'age_main': lista_age_main,
    'metallicity': lista_metallicity,
    'm_star': lista_m_star,
    'E_BV': lista_E_BVs,
    'luminosity': lista_luminosity,
    'accretion_power': lista_accretion_power,
    'agn_Lx_total': lista_agn_Lx_total
}

df = pd.DataFrame(data)

# Calculate Kendall's Tau correlations
kendall_corr = df.corr(method='kendall')

# Calculate Pearson correlations
pearson_corr = df.corr(method='pearson')

# Find the common color scale limits
cmin = min(pearson_corr.values.min(), kendall_corr.values.min())
cmax = max(pearson_corr.values.max(), kendall_corr.values.max())

# Create a mask for the upper and lower triangles
mask_upper = np.triu(np.ones_like(pearson_corr), k=1)
mask_lower = np.tril(np.ones_like(kendall_corr), k=-1)

# Exclude the diagonal elements
for i in range(mask_upper.shape[0]):
    mask_upper[i, i] = True
    mask_lower[i, i] = True

# Set up the figure
fig, ax = plt.subplots(figsize=(10, 8))

# Create the combined heatmap with diagonal elements excluded
sns.heatmap(pearson_corr, mask=mask_lower, annot=True, cmap='coolwarm',
    ↳linewidths=0.5, ax=ax, cbar=False)
sns.heatmap(kendall_corr, mask=mask_upper, annot=True, cmap='coolwarm',
    ↳linewidths=0.5, ax=ax, cbar_kws={'label': 'Coefficient'}, vmin=cmin, vmax=cmax)

plt.title('Pearson Correlation')
```

```
plt.ylabel('Kendall  $\tau$  Correlation ')
plt.xlabel('Correlation Heatmap', fontsize = 20)
plt.show()
```

output_15_0.png

```
[278]: import scipy.stats as stats

spearman_corr, p_value = stats.spearmanr(lista_m_star, lista_sfr)

print(f"Spearman Correlation: {spearman_corr}")
print(f"P-Value: {p_value}")
```

Spearman Correlation: 0.13684210526315788
P-Value: 0.5764173798364027

```
[26]: plt.scatter(lista_m_star, lista_sfr)
plt.xscale('log')
plt.yscale('log')
```

output_17_0.png

```
[27]: import matplotlib.pyplot as plt
from matplotlib.colors import Normalize
from mpl_toolkits.axes_grid1 import make_axes_locatable

# Create a 2x2 figure
fig, axes = plt.subplots(2, 2, figsize=(12, 10), dpi=110)

# Define the colormap and normalization
cmap = plt.get_cmap('coolwarm')
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))

# Plot 1
```



```

scatter0 = axes[0, 0].scatter(lista_m_star, lista_agn_Lx_total,
    ↪c=lista_chi2_red, cmap=cmap, norm=norm)
axes[0, 0].errorbar(lista_m_star, lista_agn_Lx_total, xerr=err_m_star,
    ↪yerr=err_agn_Lx_total, fmt='none', color='black', alpha=0.2)
axes[0, 0].set_xlabel('Total Stellar Mass [ $M_{\odot}$  $]')
axes[0, 0].set_ylabel('agn_Lx_total')
axes[0, 0].set_xscale('log')
axes[0, 0].set_yscale('log')

# Plot 2
scatter1 = axes[0, 1].scatter(lista_age_main, lista_sfr, c=lista_chi2_red,
    ↪cmap=cmap, norm=norm)
axes[0, 1].errorbar(lista_age_main, lista_sfr, yerr=err_sfr, xerr=err_age_main,
    ↪fmt='none', color='black', alpha=0.2)
axes[0, 1].set_xlabel('Age of the Main Stellar Population [Myr $]')
axes[0, 1].set_ylabel('SFR [ $M_{\odot} \text{ yr}^{-1}$  $]')

# Plot 3
scatter2 = axes[1, 0].scatter(lista_age_main, lista_E_BVs, c=lista_chi2_red,
    ↪cmap=cmap, norm=norm)
axes[1, 0].errorbar(lista_age_main, lista_E_BVs, xerr=err_age_main,
    ↪yerr=err_E_BVs, fmt='none', color='grey', alpha=0.2)
axes[1, 0].set_xlabel('Age of the Main Stellar Population [Myr $]')
axes[1, 0].set_ylabel('E(B-V) [mag]')

# Plot 4
scatter3 = axes[1, 1].scatter(lista_luminosity, lista_accretion_power,
    ↪c=lista_chi2_red, cmap=cmap, norm=norm)
axes[1, 1].errorbar(lista_luminosity, lista_accretion_power,
    ↪xerr=err_luminosity, yerr=err_accretion_power, fmt='none', color='black',
    ↪alpha=0.2)
axes[1, 1].set_xlabel('Luminosity')
axes[1, 1].set_ylabel('Accretion Power')
axes[1, 1].set_xscale('log')
axes[1, 1].set_yscale('log')

# Adjust layout
plt.tight_layout()

# Add a colorbar on the right
cbar_ax = fig.add_axes([0.92, 0.11, 0.03, 0.77])
cbar = plt.colorbar(scatter3, cax=cbar_ax)
cbar.set_label(r'$\chi^2_{red}$')

# Show the plot
plt.show()

```

output_18_0.png

```
[28]: # Create a 2x2 figure
fig, axes = plt.subplots(1, 2, figsize=(10, 5), dpi=110)

# Define the colormap and normalization
cmap = plt.get_cmap('coolwarm')
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))

# Plot 2
scatter1 = axes[0].scatter(lista_age_main, lista_sfr, c=lista_chi2_red,
    cmap=cmap, norm=norm)
axes[0].errorbar(lista_age_main, lista_sfr, yerr=err_sfr, xerr=err_age_main,
    fmt='none', color='black', alpha=0.2)
axes[0].set_xlabel('Age of the Main Stellar Population [Myr]')
axes[0].set_ylabel('SFR [M_{\odot} \; yr^{-1}]')

# Plot 3
scatter2 = axes[1].scatter(lista_age_main, lista_E_BVs, c=lista_chi2_red,
    cmap=cmap, norm=norm)
axes[1].errorbar(lista_age_main, lista_E_BVs, xerr=err_age_main, yerr=err_E_BVs,
    fmt='none', color='grey', alpha=0.2)
axes[1].set_xlabel('Age of the Main Stellar Population [Myr]')
axes[1].set_ylabel('E(B-V) [mag]')

# Adjust layout
plt.tight_layout()

# Add a colorbar on the right
cbar_ax = fig.add_axes([0.92, 0.11, 0.03, 0.77])
cbar = plt.colorbar(scatter3, cax=cbar_ax)
cbar.set_label(r'$\chi^2_{red}$')

# Show the plot
plt.show()
```

output_19_0.png

```
[69]: from scipy.stats import gaussian_kde

fig, axes = plt.subplots(2, 1, figsize=(5, 10), dpi=110)

# Define the colormap and normalization
cmap = plt.get_cmap('coolwarm')
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))

# Plot 1
scatter0 = axes[0].scatter(lista_m_star, lista_agn_Lx_total, c=lista_chi2_red,
    ↪ cmap=cmap, norm=norm)
plot0 = axes[0].plot(np.array(lista_m_star), (np.array(lista_m_star))**3.
    ↪ 5, c='grey', linestyle='dashed')
axes[0].errorbar(lista_m_star, lista_agn_Lx_total, xerr=err_m_star,
    ↪ yerr=err_agn_Lx_total, fmt='none', color='black', alpha=0.2)
#axes[0].set_xlabel('Total Stellar Mass [ $M_{\odot}$  $]')
axes[0].set_ylabel('AGN Total X-ray Luminosity [W]')
axes[0].set_xscale('log')
axes[0].set_yscale('log')

# Plot 2
scatter1 = axes[1].scatter(lista_m_star, lista_sfr, c=lista_chi2_red, cmap=cmap,
    ↪ norm=norm)
axes[1].errorbar(lista_m_star, lista_sfr, xerr=err_m_star, yerr=err_sfr,
    ↪ fmt='none', color='black', alpha=0.2)
axes[1].set_xlabel('Total Stellar Mass [ $M_{\odot}$  $]')
axes[1].set_ylabel('SFR [ $M_{\odot}$  \; yr-1 $]')
#axes[1].set_xscale('log')
#axes[1].set_yscale('log')
axes[1].set_xlim(10**10, 10**11)

kde = gaussian_kde([lista_m_star, lista_sfr])
xi, yi = np.mgrid[np.min(lista_m_star):np.max(lista_m_star):50j, np.
    ↪ min(lista_sfr):np.max(lista_sfr):50j]
zi = kde(np.vstack([xi.flatten(), yi.flatten()]))
contours = axes[1].contour(xi, yi, zi.reshape(xi.shape), levels=5,
    ↪ colors='k', alpha=0.1)
```

```

# Create density contours
plt.contour(xi, yi, zi.reshape(xi.shape), levels=5, cmap="YlGnBu",alpha=0.1)

# Adjust layout
#plt.tight_layout()

# Add a colorbar on the right
cbar_ax = fig.add_axes([0.92, 0.11, 0.03, 0.77])
cbar = plt.colorbar(scatter3, cax=cbar_ax)
cbar.set_label(r'$\chi^2_{red}$')

# Show the plot
plt.show()

```

output_20_0.png

```
[1]: luminosity = np.array()**3.5
```

```

-----
NameError                                Traceback (most recent call last)
Cell In[1], line 1
----> 1 luminosity = np.array()**3.5

NameError: name 'np' is not defined

```

```
[15]: rango = np.linspace(np.min(lista_m_star),np.max(lista_m_star),20)
```

```
[18]:
```

```
[18]: [<matplotlib.lines.Line2D at 0x129440910>]
```

output_23_1.png

```
[514]: fig, axes = plt.subplots(2, 1, figsize=(5, 10), dpi=110)

# Define the colormap and normalization
cmap = plt.get_cmap('coolwarm')
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))

# Plot
# Plot 2
scatter1 = axes[0].scatter(lista_age_main, lista_sfr, c=lista_chi2_red,
    cmap=cmap, norm=norm)
axes[0].errorbar(lista_age_main, lista_sfr, yerr=err_sfr, xerr=err_age_main,
    fmt='none', color='black', alpha=0.2)
#axes[0].set_xlabel('Age of the Main Stellar Population [$Myr$]')
axes[0].set_ylabel('SFR [ $M_{\odot}$  \; yr-1$]')

# Plot 3
scatter2 = axes[1].scatter(lista_age_main, lista_E_BVs, c=lista_chi2_red,
    cmap=cmap, norm=norm)
axes[1].errorbar(lista_age_main, lista_E_BVs, xerr=err_age_main, yerr=err_E_BVs,
    fmt='none', color='grey', alpha=0.2)
axes[1].set_xlabel('Age of the Main Stellar Population [$Myr$]')
axes[1].set_ylabel('E(B-V) [mag]')

# Add a colorbar on the right
cbar_ax = fig.add_axes([0.92, 0.11, 0.03, 0.77])
cbar = plt.colorbar(scatter3, cax=cbar_ax)
cbar.set_label(r'$\chi^2_{red}$')

# Show the plot
plt.show()
```

output_24_0.png

```
[86]: fig, axes = plt.subplots(1,1, figsize=(5, 5), dpi=110)

# Define the colormap and normalization
cmap = plt.get_cmap('coolwarm')
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))
```

```

# Plot 4
scatter3 = axes.scatter(lista_luminosity, lista_accretion_power,
    ↳c=lista_chi2_red, cmap=cmap, norm=norm)
axes.errorbar(lista_luminosity, lista_accretion_power, xerr=err_luminosity,
    ↳yerr=err_accretion_power, fmt='none', color='black', alpha=0.2)
axes.set_xlabel('Luminosity [W]')
axes.set_ylabel('Accretion Power [W]')
axes.set_xscale('log')
axes.set_yscale('log')
axes.plot(x_fit, y_fit, 'r', label=f'0.78x -7.47e+36',c='black',alpha=0.
    ↳5,linestyle='--')

# Adjust layout
#plt.tight_layout()

# Add a colorbar on the right
cbar_ax = fig.add_axes([0.92, 0.11, 0.03, 0.77])
cbar = plt.colorbar(scatter3, cax=cbar_ax)
cbar.set_label(r'$\chi^2_{red}$')

# Show the plot
axes.legend()
plt.show()

```

/tmp/ipykernel_71973/1811965718.py:16: UserWarning: color is redundantly defined by the 'color' keyword argument and the fmt string "r" (-> color=(1.0, 0.0, 0.0, 1)). The keyword argument will take precedence.

```

axes.plot(x_fit, y_fit, 'r', label=f'0.78x
-7.47e+36',c='black',alpha=0.5,linestyle='--')

```

output_25_1.png

```

[73]: # Sample data
x = np.array(lista_luminosity)
y = np.array(lista_accretion_power)

# Fit a 2nd-degree (quadratic) polynomial
degree = 1
coefficients = np.polyfit(x, y, degree)

```

```

# Create a polynomial function from the coefficients
poly_fit = np.poly1d(coefficients)

# Generate x values for the fitted curve
x_fit = np.linspace(min(x), max(x), 100)

# Calculate the corresponding y values using the polynomial fit
y_fit = poly_fit(x_fit)

# Plot the original data points and the fitted curve
plt.scatter(x, y, label='Data Points')
plt.plot(x_fit, y_fit, 'r', label=f'Polynomial Fit (Degree {degree})')

plt.xlabel('X')
plt.ylabel('Y')
plt.legend()
plt.grid(True)
plt.show()

```

output_26_0.png

```
[74]: coefficients
```

```
[74]: array([ 7.87378076e-01, -7.47682215e+36])
```


- 0.0.2 **Analisis E(B-V) vs AGEMAIN:** Previous studies have suggested that dust reddening in star-forming galaxies is correlated with the SFR, which can be well estimated with the intrinsic H α luminosity (e.g. Kennicutt 1998; Calzetti et al. 2010). Galaxies with large SFR (or high luminosity) show strong global extinction in the emission lines (e.g. Wang & Heckman 1996; Charlot & Fall 2000; Calzetti 2001; Stasińska & Sodr  2001; Afonso et al. 2003; Kewley, Geller & Jansen 2004; Zoran, Barkana & Thompson 2006; Calzetti et al. 2007; Garn et al. 2010)
- 0.0.3 In addition, it has been recognized that dust reddening might also be a function of gas-phase metallicity, that is, the reddening and extinction increase with metallicity. For instance, the average reddening to Hii regions in an individual galaxy is correlated with the metallicity in the disc (e.g. Quillen & Yukita 2001; Boissier et al. 2004). For the case of whole galaxies, the relationship between reddening and metallicity also exists (e.g. Heckman et al. 1998; Buat et al. 2002; Asari et al. 2007). It is also supported by the fact that the low-metallicity galaxies such as blue compact galaxies are usually less reddened (e.g. Kong 2004).
- 0.0.4 Recently, Garn & Best (2010) also found a significant correlation between dust extinction and metallicity; however, they claimed that the dependency of reddening on stellar mass is more fundamental.

COMO ESTO ULTIMO NO SE VE REFLEJADO EN LOS RESULTADOS; PARA LOA PROXIMA PROBAR MAS VALORES DE METALICIDAD HABLARLO EN LA DISCUSI N

(<https://academic.oup.com/mnras/article/421/1/486/990187>)

```
[280]: spearman_corr, p_value = stats.spearmanr(lista_luminosity, lista_accretion_power)

print(f"Spearman Correlation: {spearman_corr}")
print(f"P-Value: {p_value}")
```

```
Spearman Correlation: 0.9596491228070174
P-Value: 8.502425115286678e-11
```

In this case, you have a Spearman correlation coefficient of approximately 0.960, and an extremely low p-value of approximately 8.50e-11. Here's how to interpret these results:

1. Spearman Correlation (0.960):
 - The Spearman correlation coefficient ranges from -1 to 1. With a value of 0.960, you have a very strong positive correlation.
 - This suggests a very strong and positive monotonic relationship between your variables. The closer the correlation coefficient is to 1, the stronger the relationship.
2. P-Value (8.50e-11):
 - The p-value is a measure of the statistical significance of the correlation.
 - An extremely low p-value, such as 8.50e-11, indicates an extremely high level of statistical significance.
 - In this case, the p-value is far less than the typical significance level of 0.05, which means you can confidently conclude that the observed correlation is statistically significant.

In summary, your data shows a very strong and positive monotonic relationship, and the correlation

is highly statistically significant. This indicates a robust and meaningful relationship between the two variables, and you can have confidence in the strength and significance of this correlation.

```
[327]: cmap = plt.get_cmap('coolwarm')

# Normalize the chi-squared values to map them to the colormap
norm = Normalize(vmin=min(lista_chi2_red), vmax=max(lista_chi2_red))

# Create a scatter plot with colors based on chi-squared values
scatter = plt.scatter(lista_age_main, lista_E_BVs, c=lista_chi2_red, cmap=cmap,
    ↪norm=norm)

# Create a colorbar
cbar = plt.colorbar(scatter)
cbar.set_label(r'$\chi^2_{red}$')

plt.errorbar(lista_age_main, lista_E_BVs, xerr=err_age_main, yerr = err_E_BVs,
    ↪fmt='none', color='grey', alpha=0.2)

plt.xlabel('Age of the Main Stellar Population [Myr]')
plt.ylabel('E(B-V)')
#plt.xscale('log')
#plt.yscale('log')

plt.grid()
plt.show()
```

output_31_0.png

```
[282]: spearman_corr, p_value = stats.spearmanr(lista_luminosity, lista_agn_L_6um)

print(f"Spearman Correlation: {spearman_corr}")
print(f"P-Value: {p_value}")
```

Spearman Correlation: 0.7684210526315789

P-Value: 0.00012145768964752966


In this case, you have a Spearman correlation coefficient of approximately 0.768, and a p-value of approximately 0.000121. Here's how to interpret these results:

1. Spearman Correlation (0.768):

- The Spearman correlation coefficient ranges from -1 to 1. A value of 0.768 indicates a relatively strong positive correlation.
 - This suggests a significant positive monotonic relationship between your variables. The closer the correlation coefficient is to 1, the stronger the relationship.
2. P-Value (0.000121):
- The p-value is a measure of the statistical significance of the correlation.
 - A p-value of 0.000121 is relatively low, which indicates a high level of statistical significance.
 - The p-value is much less than the typical significance level of 0.05, which means you can confidently conclude that the observed correlation is statistically significant.

In summary, your data shows a strong positive monotonic relationship, and the correlation is statistically significant. This indicates a meaningful and robust relationship between the two variables, and you can have confidence in the strength and significance of this correlation.

[314]:



output_34_0.png

Resultados fuertemente correlacionados: - age-main y sfr (Pearson) -> HIGH SFR - LOW MAIN AGE - age-main y m_star (Pearson) - accretion_power y m_star (Kendall) - sfr y E_BV (Pearson) - age_main y E_BV (Pearson) - age_main y Luminosity (Pearson) - m_star y luminosity (Pearson) - luminosity y accretion power (Pearson) - m_star y agn_Lx_total (Pearson) - luminosity y agn_Lx_total (Kendall) - agn_Lx_total y accretion power (kendall)

[]: